

Projekt 5 — Klasyfikacja Typu Pogody

Autonomiczne Systemy Ekspertyzy i Eksploracji Danych

Karolina Wajszczuk 198009, Sebastian Kuczera 198118

28.06.2026

Spis treści

1	Cel projektu	2
2	Architektura pipeline'u	2
2.1	Infrastruktura AWS	2
3	Dane	3
3.1	Pozyskiwanie danych	3
3.2	Cechy	3
4	Klasyfikacja regułowa	4
4.1	Zasada działania	4
4.2	Klasy i reguły	4
4.3	Przykładowy rozkład klas	4
5	Model uczenia maszynowego	5
5.1	Podział danych	5
5.2	Algorytm	5
6	Wyniki	5
6.1	Metryki	5
6.2	Classification Report	6
6.3	Podsumowanie wizualne	6
6.4	Macierz pomyłek	7
6.5	Porównanie reguł i modelu ML	7
7	Predykcja pojedynczego przykładu	8
8	Ograniczenia i możliwe usprawnienia	8
8.1	Ograniczenia	8
8.2	Możliwe usprawnienia	9

1 Cel projektu

Celem projektu jest zbudowanie systemu klasyfikacji warunków pogodowych opartego na danych rzeczywistych pobieranych z REST API, z wykorzystaniem infrastruktury chmurowej Amazon Web Services. System przetwarza surowe pomiary temperatury, wilgotności, ciśnienia atmosferycznego, prędkości wiatru, opadów oraz zachmurzenia z czterech stacji pomiarowych. Zaimplementowano kompletny pipeline danych obejmujący zapis 2000 pomiarów do chmury, etykietowanie regułami, trening modelu uczenia maszynowego oraz wizualizację wyników. Kluczowym etapem jest etykietowanie, czyli transformacja surowych pomiarów w oznakowany zbiór danych. Każdy rekord otrzymuje etykietę klasy pogodowej wyznaczoną przez zestaw reguł eksperckich opartych na progach fizycznych. Na tak przygotowanym zbiorze danych trenowany jest model Random Forest. Dzięki użyciu lasu losowego jako zespół drzew decyzyjnych, zyskujemy uśrednienie wyników, co minimalizuje ryzyko przeuczenia modelu które występuje w przypadku implementacji pojedynczego drzewa decyzyjnego. Zadaniem modelu jest nauczenie się tych samych wzorców klasyfikacyjnych — tak aby model mógł samodzielnie klasyfikować nowe, niewidziane wcześniej pomiary bez konieczności stosowania reguł.

2 Architektura pipeline’u

Pipeline realizowany jest w całości w środowisku Amazon SageMaker jako notebook Jupyter. Każda sekcja notebooka odpowiada jednemu etapowi przetwarzania — dane surowe i przetworzone są wyraźnie rozdzielone i persystowane w Amazon S3.

```
Weather REST API
|
Section 2: Ingestion --> s3://weather-classification-projekt/
                        raw/raw_weather.json
|
Section 3: Processing --> s3://weather-classification-projekt/
                        processed/labelled_weather.csv
|
Section 4: Training --> s3://weather-classification-projekt/
                        splits/ (X_train, X_test, y_train, y_test)
|
Section 5: Visualization --> s3://weather-classification-projekt/
                             reports/visual_summary.png
Section 6: Prediction --> predykcja dla pojedynczego przykładu
                        ze zbioru testowego
```


2.1 Infrastruktura AWS

Projekt wykorzystuje dwie usługi AWS:

- **Amazon S3 - Simple Storage Service** — odpowiada za przechowywanie danych na każdym etapie pipeline’u. Bucket `weather-classification-projekt` zawiera cztery foldery: `raw/`, `processed/`, `splits/` oraz `reports/`. Zapis i odczyt danych z S3 odbywa się przez bibliotekę `boto3`.

- **Amazon SageMaker** — środowisko wykonawcze notebooka Jupyter. Instancja typu `ml.t3.medium` zapewnia środowisko Python z preinstalowanymi bibliotekami oraz dostęp do S3 przez rolę IAM `LabRole`.

Na rysunku 1 przedstawiona jest struktura bucketu S3 po wykonaniu pełnego pipeline'u.



Rysunek 1: Struktura bucketu S3 z danymi na wszystkich etapach pipeline'u

3 Dane

3.1 Pozyskiwanie danych

Dane pobierane są z REST API przy użyciu biblioteki `requests`. Autoryzacja odbywa się przez nagłówek `HTTP Authorization: Bearer STUDENT_TOKEN_2026`. Notebook najpierw odpytuje endpoint `/weather/stations` o listę dostępnych stacji, a następnie pobiera dane z każdej z nich przez endpoint `/weather/batch`.

Dostępne stacje: **GDN_01**, **GDN_02**, **GDY_01**, **SOP_01** Gdańsk, Gdynia, Sopot. Z każdej stacji pobieranych jest 500 rekordów, co daje łącznie **2000 pomiarów**. Pomiaru wykonywane są co 10 minut i obejmują ostatnie około 3 dni. Surowe dane zapisywane są bez modyfikacji do S3 jako lista słowników w formacie JSON — stanowi to warstwę *raw storage* zgodnie z wymaganiami projektu.

3.2 Cechy

Każdy rekord zawiera następujące pola:

Pole	Jednostka	Użyte do klasyfikacji
timestamp	—	nie
station_id	—	nie
temperature	°C	tak
humidity	%	tak
pressure	hPa	tak
wind_speed	m/s	tak
rain_mm	mm	tak
cloud_cover	%	tak
wind_direction	°	nie

Kolumny `wind_direction`, `station_id` i `timestamp` są pomijane podczas treningu, ponieważ nie wnoszą informacji klasyfikacyjnej istotnej dla określenia typu pogody.

4 Klasyfikacja regułowa

4.1 Zasada działania

Każdy pomiar klasyfikowany jest przez funkcję `classify_weather`, która sprawdza warunki w ustalonej kolejności hierarchicznej, pierwsza pasująca reguła wygrywa. Reguły oparte są na progach fizycznych wyznaczonych na podstawie analizy rozkładu wartości w datasetcie. W klasach niedeszczowych wprowadzono warunek braku opadów, który zapobiega przypisaniu etykiety opartej na wietrze, temperaturze lub zachmurzeniu do rekordu zawierającego opady.

4.2 Klasy i reguły

Klasa	Warunki
storm-risk	pressure < 1005 AND rain_mm > 1.0 AND cloud_cover > 80
heavy-rain	rain_mm > 1.5
unstable	pressure < 1005 AND humidity > 80 AND rain_mm < 0.3
rainy	rain_mm ≥ 0.3
windy	wind_speed > 9 AND rain_mm = 0
warm	temperature > 18 AND cloud_cover < 50 AND rain_mm = 0
cold	temperature < 12 AND rain_mm = 0
cloudy	cloud_cover > 70 AND rain_mm = 0
stable	żaden z powyższych warunków

Progi zostały dobrane na podstawie analizy rozkładu wartości w zbiorze danych. Zastosowano próg `rain_mm` równy 0.3 mm dla klasy `rainy` aby nie klasyfikować mżawki i rosy jako przypadków deszczowych oraz zastosowano wartość progową `wind_speed` 9 m/s dla klasy `windy` aby pokrywała się z danymi w datasetcie.

4.3 Przykładowy rozkład klas

Po etykietowaniu rozkład klas w datasetcie przedstawia się następująco:

Klasa	Liczba rekordów
rainy	805
windy	268
stable	246
heavy-rain	277
cloudy	172
warm	112
unstable	79
storm-risk	41
Łącznie	2000

Klasa `cold` nie wystąpiła w datasetcie, ponieważ temperatury w badanym okresie nie

spadały poniżej progu 12°C. Jest to naturalne ograniczenie datasetu wynikające z sezonu i regionu geograficznego, nie z błędu w regułach.

5 Model uczenia maszynowego

5.1 Podział danych

Dataset dzielony jest na zbiór treningowy i testowy w proporcji 60/40 przy użyciu funkcji `train_test_split` z biblioteki `scikit-learn` z parametrem `random_state=42` zapewniającym powtarzalność podziału. Przy 2000 rekordach daje to 1200 rekordów treningowych i 800 testowych. Zbiory zapisywane są do S3 w folderze `splits/`, dzięki czemu sekcja wizualizacji i predykcji korzysta z identycznego podziału bez konieczności ponownego treningu.

5.2 Algorytm

Zastosowano las losowy `RandomForestClassifier` z biblioteki `scikit-learn`. Las losowy to zespół drzew decyzyjnych trenowanych na losowych podzbiorach danych i cech. Każde drzewo daje własny wynik, a predykcja końcowa wyznaczana jest przez głosowanie większościowe. W porównaniu do pojedynczego drzewa decyzyjnego las losowy jest odporniejszy na przeuczenie i lepiej generalizuje na klasach rzadkich, co jest istotne przy nierównym rozkładzie klas w datasetcie.

6 Wyniki

6.1 Metryki

Do oceny modelu użyto standardowych metryk klasyfikacji wieloklasowej:

- **Precision** — spośród wszystkich rekordów przewidzianych jako dana klasa, jaki odsetek faktycznie do niej należy.
- **Recall** — spośród wszystkich rekordów rzeczywiście należących do danej klasy, jaki odsetek model poprawnie wykrył.
- **F1-score** — średnia harmoniczna precision i recall, szczególnie istotna przy nierównym rozkładzie klas.
- **Accuracy** — ogólny odsetek poprawnych predykcji.


6.2 Classification Report

Klasa	Precision	Recall	F1-score	Support
cloudy	0.92	1.00	0.96	71
heavy-rain	0.97	1.00	0.99	106
rainy	0.98	1.00	0.99	309
stable	0.98	1.00	0.99	106
storm-risk	1.00	0.43	0.60	14
unstable	1.00	0.69	0.81	35
warm	0.94	1.00	0.97	45
windy	1.00	1.00	1.00	114
accuracy			0.98	800
macro avg	0.97	0.89	0.91	800
weighted avg	0.98	0.98	0.97	800

Model osiągnął dokładność 0.9762 na zbiorze testowym. Klasy posiadające dużą ilość pomiarów, powyżej 100 w całkowitym zbiorze danych, klasyfikowane są ze skutecznością $F1 \geq 0.96$. Las losowy skutecznie odtworzył logikę reguł eksperckich dla wszystkich klas z wyjątkiem **storm-risk** i **unstable**. W obu przypadkach przyczyną jest mała liczba przykładów treningowych. Przy tak małej próbce model nie ma wystarczającej liczby danych by nauczyć się granic decyzyjnych dla tych klas.

6.3 Podsumowanie wizualne

Na rysunku 2 przedstawione są cztery wykresy podsumowujące wyniki: rozkład klas w pełnym datasetcie, precision/recall/F1 per klasa na zbiorze testowym, macierz pomyłek oraz porównanie F1 reguł i modelu ML.



Rysunek 2: Podsumowanie wizualne wyników klasyfikacji

6.4 Macierz pomyłek

Macierz pomyłek pokazuje dla każdej prawdziwej klasy jak model rozłożył predykcje. Na przekątnej znajdują się trafienia, poza przekątną błędy. Kolory reprezentują proporcję trafień w danej klasie, normalizacja per wiersz, liczby w komórkach to surowe zliczenia.

Błędy modelu dotyczą dwóch klas. Klasa **storm-risk** jest mylona z **heavy-rain** dla 3. przypadków oraz z **rainy** dla 5. przypadków. Wynika to z konieczności jednoczesnego spełnienia trzech warunków, których model nie nauczył się rozróżniać przy małej liczbie przykładów treningowych. Klasa **unstable** jest natomiast mylona z **cloudy** dla 6. przypadków, z **stable** dla 2. przypadków oraz z **warm** dla 3. przypadków. Pozostałe klasy klasyfikowane są bezbłędnie.

6.5 Porównanie reguł i modelu ML

Wykres F1-score: Rules vs ML pokazuje że dla 6 z 8 klas model ML osiąga F1 praktycznie równy 1.0, identyczny jak reguły eksperckie. Różnice obserwujemy jedynie dla **storm-risk** F1 = 0.60 oraz **unstable** F1 = 0.81, co wynika wyłącznie z niedoboru danych treningowych dla tych klasy, a nie z ograniczeń algorytmu.

7 Predykcja pojedynczego przykładu

Działanie modelu demonstrujemy na pojedynczym, losowym rekordzie ze zbioru testowego. Wynik reprezentują parametry pogodowe rekordu, etykietę wyznaczoną przez reguły, predykcję modelu oraz poziom pewności predykcji.

```
=====
WEATHER PREDICTION – SINGLE SAMPLE
=====
Temperature: 16.71 °C
Humidity: 84.92 %
Pressure: 1023.32 hPa
Wind speed: 8.34 m/s
Rain: 0.06 mm
Cloud cover: 86 %
-----
True label: cloudy
Prediction: cloudy
Confidence: 90.0%
Match: correct
=====
```

Rysunek 3: Przykładowe wyjście sekcji predykcji, rekord ze zbioru testowego

Dla przedstawionego przykładu: temperatura 16.71°C, wilgotność 84.92%, ciśnienie 1023.32 hPa, prędkość wiatru 8.34 m/s, opady 0.06 mm, zachmurzenie 86%. Reguła klasyfikuje rekord jako cloudy, a model poprawnie predykuje cloudy z pewnością 90%.

8 Ograniczenia i możliwe usprawnienia

8.1 Ograniczenia

- **Dane syntetyczne API** — analiza rozkładów wartości wskazuje że API generuje dane w sposób syntetyczny, a nie na podstawie rzeczywistych pomiarów stacyjnych. Wszystkie cztery stacje wykazują niemal identyczne średnie wartości cech, co nie odpowiada rzeczywistej zmienności przestrzennej warunków pogodowych w Trójmieście.
- **Klasa cold nieobecna w datasetcie** — temperatury w badanym okresie nie spadały poniżej progu 12°C. Modelu nie można stosować do klasyfikacji warunków zimowych bez dostarczenia odpowiednich przykładów treningowych.
- **Mała liczba przykładów storm-risk oraz unstable** <100 rekordów to za mało by model nauczył się granic decyzyjnych dla tych klasy. Skutkuje to niskim recall.
- **Krótki przedział czasowy** — dane obejmują około 3 dni pomiarów z czterech stacji w jednym regionie. Model nie może być traktowany jako ogólny klasyfikator warunków pogodowych.

8.2 Możliwe usprawnienia

- Pobieranie danych z dłuższego okresu, w celu uzyskania przykładów klas nieobecnych w krótkim oknie czasowym `cold` oraz zwiększenia liczby przykładów klas rzadkich `storm-risk`, `unstable` .
- Automatyczne wyznaczanie progów w regułach eksperckich na podstawie analizy rozkładu danych np. percentyle zamiast ręcznego dobierania wartości.